2.4 String

- Definition and operations
- Applications

2.4.1. Definition

- 串：零个或多个字符组成的有限序列。
- 串长度：串中所包含的字符个数。
- 空串：长度为0的串，记为：“ ”。
- 非空串通常记为：　　S=" s1 s2 …… sn "
  - 其中：S是串名，双引号是定界符，双引号引起来的部分是串值，si（1≤i≤n）是一个任意字符。
  - 字符集：ASII码、扩展ASII码、Unicode字符集
- 子串：串中任意个连续的字符组成的子序列。
- 主串：包含子串的串。
- 子串的位置：子串的第一个字符在主串中的序号。

ADT String{

数据对象：D = { a_i|a_i∈CharacterSet，i=1,2,…,n, n ≥0 }

数据关系：R = {<a_{i-1}, a_i>| a_{i-1}, a_i∈D，i=2,3,…,n }

基本操作：

StrAssign(t , chars)

初始条件： chars是一个字符串常量。

操作结果：生成一个值为chars的串t 。

StrConcat(s, t)

初始条件：串s, t 已存在。

操作结果：将串t联结到串s后形成新串存放到s中。

StrLength(t)

初始条件：字符串t已存在。

操作结果：返回串t中的元素个数，称为串长。

SubString (s, pos, len, sub)

初始条件：串s, 已存在, 1≦pos≦StrLength(s)且0≦len≦StrLength(s) –pos+1。

操作结果：用sub返回串s的第pos个字符起长度为len的子串。

……

} ADT String

串的基本操作：

（1） 创建串 StringAssign (s,string_constant)

（2）判断串是否为空 StringEmpty(s)

（3）计算串长度 Length(s)

（4）串连接 Concat(s1,s2)

（5）求子串 SubStr(s1,s2,start,len)

（6）子串的定位 Index(s1,s2)

（7）子串的插入和删除

2.4.2 串的存储设计

- 顺序串：
  - 用数组来存储串中的字符序列。
- 非压缩形式
  - 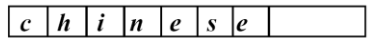

- 压缩形式
  - 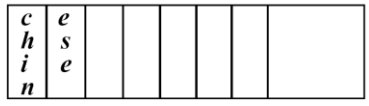

- 如何表示串的长度？
  - 方法一：用一个变量来表示串的实际长度，同一般线性表
  - 方法二：在串尾存储一个不会在串中出现的特殊字符作为串的终结符，表示串的结尾。

0	1	2	3	4	5	6			Max
w	o	r	k	e	r	空	----------	----------	闲

5

0	1	2	3	4	5	6			Max
w	o	r	k	e	r	\0	空	----------	闲

- 链接串：
  - 用链接存储结构来存储串。

串的链式存储结构和线性表的串的链式存储结构类似，采用单链表来存储串，结点的构成是：

- data域：存放字符，data域可存放的字符个数称为结点的大小；
- next域：存放指向下一结点的指针。

若每个结点仅存放一个字符，则结点的指针域就非常多，造成系统空间浪费，为节省存储空间，考虑串结构的特殊性，使每个结点存放若干个字符，这种结构称为块链结构。

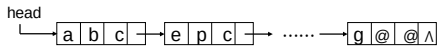

块大小为3串的块链式存储结构示意图

2.4.3 串的模式匹配算法 (Pattern Matching)

子串定位运算又称为模式匹配(Pattern Matching)或串匹配(String Matching)，此运算的应用在非常广泛。例如，在文本编辑程序中，我们经常要查找某一特定单词在文本中出现的位置。显然，解此问题的有效算法能极大地提高文本编辑程序的响应性能。

在串匹配中，一般将主串称为目标串，子串称之为模式串。设S为目标串，T为模式串，且不妨设：

$S=$“$s_1s_2\cdots s_n$” $T=$“$t_1\cdots t_m$”

朴素模式匹配算法(Brute-Force算法)：枚举法

从主串S的第一个字符开始和模式T 的第一个字符进行比较，若相等，则继续比较两者的后续字符；否则，从主串S的第二个字符开始和模式T 的第一个字符进行比较，重复上述过程，直到T 中的字符全部比较完毕，则说明本趟匹配成功；或S中字符全部比较完，则说明匹配失败。

其算法段为：

```
for(i=1;i<=n-m+1;i++){
    if(S[i..i+m-1]=T[1..m]
        return i;
```

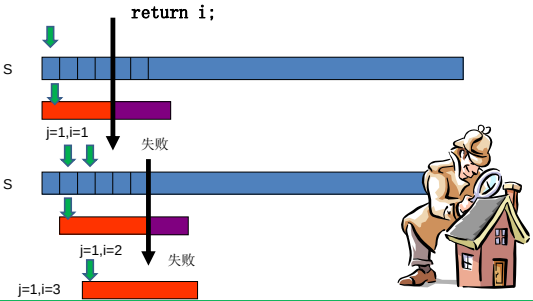

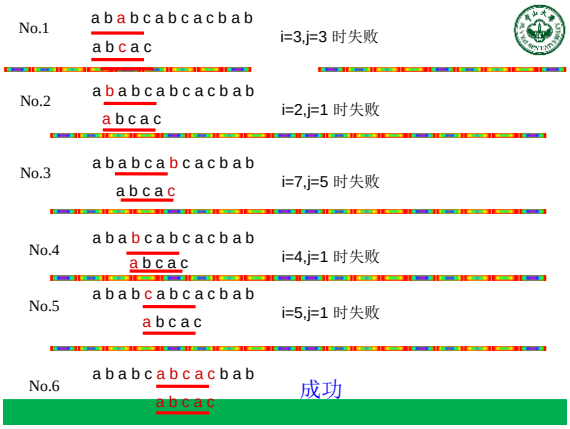

```
int index-1(sstring s,sstring t)
{   int i,j,k;
    int n=s.length;
    int m=t.length;
    for(i=1;i<=n-m+1;i++)
    {   j=1;k=i;
        while(j<=m && s.ch[k]==t.ch[j])
        {       k++; j++;    }
        if (j>m)    return i;
    }
    return –1;
}
```

```
int index-2(sstring s,sstring t)
{   int i=1,j=1;
    int n=s.length;
    int m=t.length;
    while (i<=n)&&(j<=m)
    {   if ( s.ch[i]==t.ch[j])
        {   i++; j++;    }
        else
        {  i=i-j+2; j=1;   }
    }
    if (j>m) return i-j+1;
     else  return –1;
    }
```

时间复杂性

最好情况下算法的平均时间复杂性 $O(n+m)$。

最坏情况下的平均时间复杂性为 $O(n*m)$。

KMP 算 法：改进的模式匹配算法

- 为什么BF算法时间性能低?
  - 在每趟匹配不成功时存在大量回溯，没有利用已经部分匹配的结果。

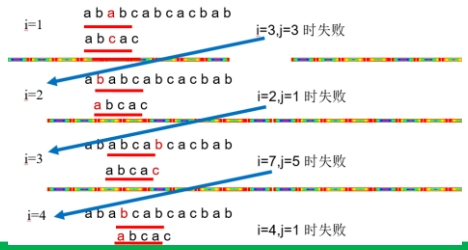

KMP 算 法：改进的模式匹配算法

- 为什么BF算法时间性能低?
  - 在每趟匹配不成功时存在大量回溯，没有利用已经部分匹配的结果。
- 如何在匹配不成功时主串不回溯?
  - 主串不回溯，模式就需要向右滑动一段距离。
- 如何确定模式的滑动距离?
  - 利用已经得到的“部分匹配”的结果
  - 将模式向右“滑动”尽可能远的一段距离(next[j])后，继续进行比较

– 出发点：利用前面匹配的结果，进行无回溯匹配

- 如何在匹配不成功时主串不回溯?
  - 主串不回溯，模式就需要向右滑动一段距离。
- 如何确定模式的滑动距离?
  - 利用已经得到的“部分匹配”的结果
  - 将模式向右“滑动”尽可能远的一段距离(next[j])后，继续进行比较

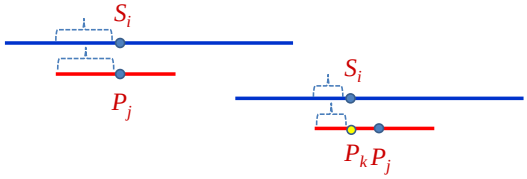

KMP 算 法

- 思考：
  - 假定：主串为 $S_1S_2\ldots S_n$
  - 模式串为 $P_1P_2\ldots P_m$
  - 当主串中的第 i 个字符和模式串中的第 j 个字符出现不匹配，主串中的第i个字符应该和模式串中的哪个字符匹配（无回溯，主串指针不回溯，模式串右移动）？

- 进一步思考
  - 假定主串中第i个字符与模式串第j个字符相比较失败，则应有$S_i \neq P_j$

$S_{i-j+1}\ S_{i-j+2}\cdots\ S_{i-k+1}S_{i-k+2}\ldots S_{i-1}\ S_i$

$P_1\ \ P_2\cdots\ \ P_{j-k+1}P_{j-k+2}\ldots P_{j-1}\ P_j$

$k<j$

$S_{i-k+1}\ S_{i-k+2}\cdots\ S_{i-1}\ S_i$

$P_1\ \ P_2\cdots\ \ P_{k-1}\ P_k$ 成立

S_i 与 P_k 进行比较

$S_{i-j+1}\ S_{i-j+2}\cdots\ S_{i-k+1}\ S_{i-k+2}\ldots S_{i-1}\ S_i$

$P_1\ \ P_2\cdots\ \ P_{j-k+1}\ P_{j-k+2}\ldots P_{j-1}\ P_j$

$P_1\ \ P_2\ldots\ \ P_{k-1}\ P_k$

- 而根据已有的匹配，有
  - $P_{j-k+1}P_{j-k+2}\ldots P_{j-1} = S_{i-k+1}S_{i-k+2}\ldots S_{i-1}$
- 因此
  - $P_{j-k+1}P_{j-k+2}\ldots P_{j-1} = P_1P_2\ldots P_{k-1}$
- 因此k值只和P以及j有关，定义为Next[j]

意义：当P_j比较失败时，右移动模式串，让P_k与当前S_i元素进行比较

- Next[j]的定义
- Next[j] =
  - 0, j=1时
  - Max{k | 1<k<j and $p_1p_2\ldots p_{k-1} = p_{j-k+1}\ldots p_{j-1}$}
  - 1,其它情况

Next数组的实质是找模式串中的最长相同的前缀和后缀。
$p_1p_2\ldots p_{k-1} = p_{j-k+1}\ldots p_{j-1}$

j	1	2	3	4	5	6	7	8
	a	b	a	a	b	c	a	c
Next[j]	0	1	1	2	2	3	1	2

j	1	2	3	4	5
	a	b	c	a	c
Next[j]	0	1	1	1	2

No.1
a b a b c a b c a c b a b
a b c a c
i=3, j=3 时失败

No.2
a b a b c a b c a c b a b
a b c a c
i=7, j=5 时失败

No.3
a b a b c a b c a c b a b
a b c a c
成功

```
int index(sstring s,sstring t)
{   int i=1,j=1;
    int n=s.length;
    int m=t.length;
    while (i<=n)&&(j<=m)
    {   if ( s.ch[i]==t.ch[j])  (j=0) || ( s.ch[i]==t.ch[j])
        {   i++; j++;   }
        else
        {  i=i-j+2; j=1;  }      j=Next[j];
    }
    if (j>m) return i-j+1;
     else  return –1;
}
```

计算Next数组的方法

1) Next[1]=0;

2) 设 Next[j]=k； 则意味着

$P_{j-k+1}P_{j-k+2}\cdots P_{j-1}=P_1P_2\cdots P_{k-1}$

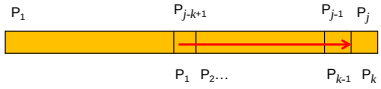

3) 求Next[j+1]

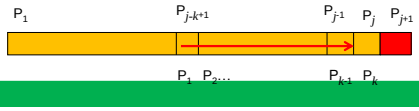

3) 求Next[j+1]

当$P_k=P_j$时 $P_{j-k+1}P_{j-k+2}\cdots P_{j-1}P_j=P_1P_2\cdots P_{k-1}P_k$

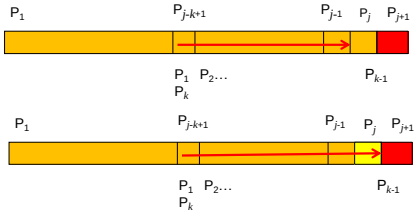

Next[j+1]=Next[j]+1;

当$P_k\neq P_j$时 $P_{j-k+1}P_{j-k+2}\cdots P_{j-1}P_j\neq P_1P_2\cdots P_{k-1}P_k$

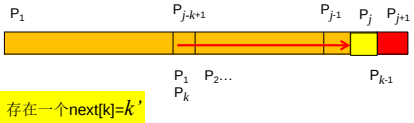

存在一个next[k]=*k'*

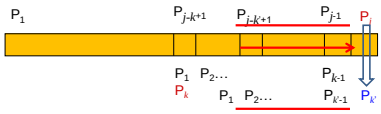

当 $P_j=P_{k'}$， Next[j+1]=Next[k]+1;

同理，若$P_j=P_{k'}$，则将模式串继续向右滑动至模式串的第next[k'] 个字符与P_j对齐，….，依次类推，直到P_j和模式串中某个字符匹配成功或者不存在k'($1<k'<j$)，则Next[j+1]=1.

Next数组的无回溯匹配计算

```
void Makenext(String p,int *pNext)
{
   int i,k; i=1;k=0;Next[1] = 0;
   while(i<Length(p))
   {
        if (k==0)||( p[i]==p[k])
        { j=j+1; k=k+1;       Next[j]=k;    }
      else k=Next[k];
}
```

Next数组特殊情况

j	1	2	3	4	5	6	7	8	9	10	11	12	13	
	a	a	a	a	a	a	a	b	b	b	c	a	a	
	0	1	2	3	4	5	6	7	1	1	1	1	2	

改进后的Next数组：

j	1	2	3	4	5	6	7	8	9	10	11	12	13	
	a	a	a	a	a	a	a	b	b	b	c	a	a	
	0	0	0	0	0	0	0	7	1	1	1	0	0	